

# **Statistische Modellierung III**

## **-Wiederholung: Lineare Modelle-**

Dr. Martin Scharpenberg

MSc Medical Biometry/Biostatistics

WiSe 2019/2020

## Das klassische lineare Regressionsmodell

## Klassisches lin. Modell - Setup

- Unabhängige Beobachtungen  $(Y_i, \mathbf{x}_i)$ ,  $i = 1, \dots, n$  einer Zielvariable  $Y_i$  und eines  $k$ -dim. Kovariablenvektors  $\mathbf{x}_i$
- Annahme:  $Y_i \sim N(\mathbf{x}_i\beta, \sigma^2)$  für  $\beta \in \mathbb{R}^k$  und  $\sigma^2 > 0$
- Die Daten folgen somit dem linearen Regressionsmodell

$$Y_i = \mathbf{x}_i\beta + U_i \text{ mit } U_i \sim N(0, \sigma^2), \quad i = 1, \dots, n$$

## Modell in Matrixschreibweise

- Definiere

$$\mathbf{Y} = (Y_1, \dots, Y_n)^T = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} x_{11} & \dots & x_{1k} \\ x_{21} & \dots & x_{2k} \\ \vdots & \vdots & \vdots \\ x_{n1} & \dots & x_{nk} \end{pmatrix}, \quad \mathbf{U} = (U_1, \dots, U_n)^T = \begin{pmatrix} U_1 \\ \vdots \\ U_n \end{pmatrix}$$

- Dann ist  $\mathbf{Y} = \mathbf{X}\beta + \mathbf{U}$ , wobei  $\mathbf{U} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$  mit  $\mathbf{0} = (0, \dots, 0)^T \in \mathbb{R}^n$  und  $\mathbf{I}_n$  die  $n$ -dimensionale Einheitsmatrix ist.
- Insgesamt folgt also:  $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$ , wobei  $N(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$  die multivariate Normalverteilung mit Erwartungswertvektor  $\mathbf{X}\beta$  und Kovarianzmatrix  $\sigma^2 \mathbf{I}_n$  ist.
- $\mathbf{X}$  wird Designmatrix genannt

## Der KQ-Schätzer und seine Eigenschaften

## Der kleinste Quadratschätzer (KQ-Schätzer)

- Zum schätzen der Regressionskoeffizienten wird in der Regel die KQ-Methode eingesetzt
- Ziel: Finde  $\arg \min_{\beta \in \mathbb{R}^k} \sum_{i=1}^n (Y_i - \mathbf{x}_i \beta)^2$
- Dieses Minimierungsproblem führt via Differentiation zum Normalgleichungssystem:

$$\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{Y}$$

- Hat  $\mathbf{X}$  vollen Rang, dann ist  $\mathbf{X}^T \mathbf{X}$  invertierbar und das Normalgleichungssystem hat die Lösung

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

## Eigenschaften des KQ-Schätzers

- Allgemein gilt:
  - Erwartungstreue:  $E(\hat{\beta}) = \beta$ ,
  - Kovarianzmatrix:  $\text{Cov}(\hat{\beta}) = (\mathbf{X}^T \mathbf{X})^{-1} \sigma^2$
- Ist zudem  $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$ , so gilt
  - $\hat{\beta} \sim N(\beta, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1})$
  - $(\hat{\beta} - \beta)^T \mathbf{X}^T \mathbf{X} (\hat{\beta} - \beta) / \sigma^2 \sim \chi_k^2$
  - $\hat{\beta}$  ist MLE für  $\beta$

## Eigenschaften des KQ-Schätzers

### Gauß-Markov-Theorem

Gilt das lineare Modell  $\mathbf{Y} = \mathbf{X}\beta + \mathbf{U}$ , mit  $E(\mathbf{U}) = \mathbf{0}$  und  $\text{Cov}(\mathbf{U}) = \sigma^2 \mathbf{I}_n$  und hat die Designmatrix  $\mathbf{X}$  vollen Rang, dann ist der KQ Schätzer  $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$  der beste lineare unverzerzte Schätzer (engl. **B**est **L**inear **U**nbiased **E**stimator, BLUE). Das heißt für jeden anderen linearen und erwartungstreuen Schätzer  $\tilde{\beta}$  von  $\beta$  gilt:

$$\text{Var}(\mathbf{c}^T \hat{\beta}) \leq \text{Var}(\mathbf{c}^T \tilde{\beta}), \quad \forall \mathbf{c} \in \mathbb{R}^k$$

und  $\exists \mathbf{c} \in \mathbb{R}^k$  mit  $\text{Var}(\mathbf{c}^T \hat{\beta}) < \text{Var}(\mathbf{c}^T \tilde{\beta})$ .



## Asymptotische Eigenschaften des KQ-Schätzers

- Betrachten nun eine unendliche Folge von fixen (nicht-zufälligen) Kovariablenvektoren  $\mathbf{x}_i$  und stochastisch unabhängigen Beobachtungen  $Y_i$ ,  $i = 1, 2, \dots$ , mit  $Y_i = \mathbf{x}_i\beta + U_i$ , wobei  $E(U_i) = 0$  und  $\text{Var}(U_i) = \sigma^2$  für alle  $i$
- Nehmen nicht mehr an, dass  $Y_i$  normalverteilt sind
- Betrachten für jedes endliche  $n$  die KQ-Schätzer der ersten  $n$  Beobachtungen,

$$\hat{\beta}_n = (\mathbf{X}_n^T \mathbf{X}_n)^{-1} \mathbf{X}_n^T \mathbf{Y}_n$$

wobei  $\mathbf{X}_n = (\mathbf{x}_1, \dots, \mathbf{x}_n)^T$  und  $\mathbf{Y}_n = (Y_1, \dots, Y_n)^T$  die Designmatrix und der Zielvariablenvektor der ersten  $n$  Beobachtungen sind

## Asymptotische Eigenschaften des KQ-Schätzers

- Unter der Annahme, dass  $\frac{1}{n}\mathbf{X}_n^T\mathbf{X}_n$  für  $n$  gegen unendlich gegen eine positiv definite Matrix  $\mathbf{V}$  konvergiert und weiteren Regularitätsannahmen (siehe z.B. Brannath, 2015), gilt

$$\sqrt{n}(\hat{\beta}_n - \beta) \xrightarrow{d} N(\mathbf{0}, \sigma^2\mathbf{V}^{-1}), \quad (1)$$

wobei " $\xrightarrow{d}$ " Konvergenz in Verteilung bedeutet.

- Hieraus folgt insbesondere die Konsistenz von  $\hat{\beta}_n$ , d.h.  $\hat{\beta}_n \xrightarrow{P} \beta$ , wobei " $\xrightarrow{P}$ " Konvergenz in Wahrscheinlichkeit heißt.
- Aus (1) folgt, dass  $\hat{\beta}_n$  bei hinreichend großem  $n$  approximativ  $N(\beta, \sigma^2(\mathbf{X}_n^T\mathbf{X}_n)^{-1})$  verteilt ist. Wir schreiben dafür auch:  $\hat{\beta}_n \overset{a}{\sim} N(\beta, \sigma^2(\mathbf{X}_n^T\mathbf{X}_n)^{-1})$ .

## Prognosen und Residuen

## Modellraum

- Unter den Annahmen des linearen Modells ( $\mu_i = E(Y_i) = \mathbf{x}_i\beta$ ) liegt der Erwartungswert  $\mu = E(\mathbf{Y}) \in \mathbb{R}^n$  im folgenden Teilraum des  $\mathbb{R}^n$ :

$$\mathcal{M} = \{ \tilde{\mu} = \mathbf{X}\beta \mid \beta \in \mathbb{R}^k \}$$

- $\mathcal{M}$  wird als *Modellraum* bezeichnet
- Wir betrachten auch das orthogonale Komplement von  $\mathcal{M}$ :

$$\mathcal{M}^\perp = \{ \tilde{\mathbf{e}} \in \mathbb{R}^n \mid \tilde{\mathbf{e}}^T \tilde{\mu} = 0 \text{ für alle } \tilde{\mu} \in \mathcal{M} \}$$

## Orthogonale Zerlegung

- Jedes  $\mathbf{Y} \in \mathbb{R}^n$  lässt sich eindeutig als Summe eines Vektors  $\hat{\mathbf{y}}$  in  $\mathcal{M}$  und eines Vektors  $\hat{\mathbf{e}}$  in  $\mathcal{M}^\perp$  zerlegen, d.h.

$$\mathbf{y} = \hat{\mathbf{y}} \oplus \hat{\mathbf{e}} \quad \text{mit eindeutigen } \hat{\mathbf{y}} \in \mathcal{M} \text{ und } \hat{\mathbf{e}} \in \mathcal{M}^\perp.$$

- Das Symbol " $\oplus$ " deutet darauf hin, dass die beiden Vektoren  $\hat{\mathbf{y}}$  und  $\hat{\mathbf{e}}$  orthogonal zueinander sind, d.h. das innere Produkt  $\hat{\mathbf{y}}^T \hat{\mathbf{e}} = \hat{\mathbf{y}}_1 \hat{\mathbf{e}}_1 + \cdots + \hat{\mathbf{y}}_n \hat{\mathbf{e}}_n$  ist gleich 0.
- Geometrisch gesehen, stehen  $\hat{\mathbf{y}}$  und  $\hat{\mathbf{e}}$  senkrecht aufeinander.

## Projektion auf den Modellraum

- $\hat{\mathbf{Y}} = \operatorname{argmin}_{\tilde{\boldsymbol{\mu}} \in \mathcal{M}} \|\mathbf{Y} - \tilde{\boldsymbol{\mu}}\|^2,$
- D.h.  $\hat{\mathbf{Y}}$  aus der orthogonalen Zerlegung ist jenes  $\tilde{\boldsymbol{\mu}} \in \mathcal{M}$  mit dem kleinsten Euklid-Abstand zu  $\mathbf{Y}$ .
- $\tilde{\boldsymbol{\mu}} \in \mathcal{M}$  ist gleichbedeutend mit  $\tilde{\boldsymbol{\mu}} = \mathbf{X}\tilde{\boldsymbol{\beta}}$  für ein  $\tilde{\boldsymbol{\beta}} \in \mathbb{R}^k$ .
- Es gilt hier:  $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ , wobei  $\hat{\boldsymbol{\beta}}$  der KQ-Schätzer von  $\boldsymbol{\beta}$  ist.
- $\hat{\mathbf{Y}} = \mathbf{P}_{\mathcal{M}}\mathbf{Y}$  ist (per Definition) die orthogonale Projektion von  $\mathbf{Y}$  auf  $\mathcal{M}$ . Sie ist auch der Vektor der Prognosen  $\hat{\mathbf{Y}}_i = \mathbf{x}_i\hat{\boldsymbol{\beta}}$ .
- $\hat{\mathbf{Y}}$  wird *Prognose* genannt

## Projektion auf den Modellraum

- Ist  $\text{Rang}(\mathbf{X}) = k$  so kann man zeigen, dass

$$\mathbf{P}_{\mathcal{M}} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T = \mathbb{H}$$

- $\mathbb{H}$  wird häufig als „Hat-Matrix“ bezeichnet
- Es gilt:

$$E(\hat{\mathbf{Y}}) = E(\mathbf{P}_{\mathcal{M}} \mathbf{Y}) = \mathbf{P}_{\mathcal{M}} E(\mathbf{Y}) = \mathbf{P}_{\mathcal{M}} \mu = \mu$$

## Residuen

- Der Vektor  $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\mathbf{Y}}$  besteht aus den Residuen  $\hat{e}_i = Y_i - \mathbf{x}_i \hat{\beta}$  der linearen Regression

- Es gilt

$$\hat{\mathbf{e}} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbb{H}\mathbf{Y} = (\mathbf{I}_n - \mathbb{H})\mathbf{Y}$$

- $\mathbf{I}_n - \mathbb{H} = \mathbf{I}_n - \mathbf{P}_{\mathcal{M}} = \mathbf{P}_{\mathcal{M}^\perp}$  ist die Projektionsmatrix auf  $\mathcal{M}^\perp$



## Eigenschaften der Residuen

- Es gilt

$$E(\hat{\mathbf{e}}) = E(\mathbf{Y}) - E(\hat{\mathbf{Y}}) = \mu - \mu = \mathbf{0}$$

- Zudem ist

$$\text{Cov}(\hat{\mathbf{e}}) = \text{Cov}(\mathbf{P}_{\mathcal{M}^\perp} \mathbf{Y}) = \mathbf{P}_{\mathcal{M}^\perp} \text{Cov}(\mathbf{Y}) \mathbf{P}_{\mathcal{M}^\perp}^T = \sigma^2 \mathbf{P}_{\mathcal{M}^\perp} \mathbf{P}_{\mathcal{M}^\perp}^T = \sigma^2 \mathbf{P}_{\mathcal{M}^\perp} = \sigma^2 (\mathbf{I}_n - \mathbb{H})$$

- Insbesondere gilt  $\text{Var}(\hat{e}_i) = \sigma^2(1 - h_{ii})$  für das  $i$ -te Diagonalelement  $h_{ii}$  von  $\mathbb{H}$ .
- Während  $\text{Var}(U_i) = \sigma^2$  unabhängig von  $i$  ist, ist  $\text{Var}(\hat{e}_i) = \sigma^2(1 - h_{ii})$  im Allgemeinen abhängig von  $i$ . Während  $\text{Cov}(U_i, U_j) = 0$  für  $i \neq j$ , ist  $\text{Cov}(\hat{e}_i, \hat{e}_j) = \sigma^2(1 - h_{ij})$  im Allgemeinen  $\neq 0$ .

## Verteilung von Prognosen und Residuen

- Wenn  $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$ , dann ist  $\mathbb{H}(\mathbf{I} - \mathbb{H}) = \mathbb{H} - \mathbb{H} = \mathbf{0}$ .
- Es folgt

$$\begin{pmatrix} \hat{\mathbf{Y}} \\ \hat{\mathbf{e}} \end{pmatrix} = \begin{pmatrix} \mathbb{H} \\ (\mathbf{I}_n - \mathbb{H}) \end{pmatrix} \mathbf{Y} \sim N \left( \begin{pmatrix} \mathbf{X}\beta \\ \mathbf{0} \end{pmatrix}, \Sigma \right)$$

mit

$$\Sigma = \sigma^2 \begin{pmatrix} \mathbb{H} \\ \mathbf{I}_n - \mathbb{H} \end{pmatrix} \mathbf{I}_n \begin{pmatrix} \mathbb{H}, \mathbf{I}_n - \mathbb{H} \end{pmatrix} = \sigma^2 \begin{pmatrix} \mathbb{H} & \mathbf{0} \\ \mathbf{0} & \mathbf{I}_n - \mathbb{H} \end{pmatrix}.$$

- $\hat{\mathbf{Y}}$  und  $\hat{\mathbf{e}}$  sind damit stochastisch unabhängig mit

$$\hat{\mathbf{Y}} \sim N(\mathbf{X}\beta, \mathbb{H}\sigma^2) \quad \text{und} \quad \hat{\mathbf{e}} \sim N(\mathbf{0}, (\mathbf{I}_n - \mathbb{H})\sigma^2).$$

## Weitere Eigenschaften von Prognosen und Residuen

- (i)  $\hat{\mathbf{Y}}$  und  $\hat{\mathbf{e}}$  sind immer orthogonal, d.h.  $\hat{\mathbf{Y}} \perp \hat{\mathbf{e}}$  (denn  $\hat{\mathbf{Y}} \in \mathcal{M}$  und  $\hat{\mathbf{e}} \in \mathcal{M}^\perp$ ),
- (ii)  $\hat{\mathbf{e}} \perp \mathbf{x}^j$  für alle Spalten  $\mathbf{x}^j$  von  $\mathbf{X}$ , denn  $\mathbf{x}^j = \mathbf{X}\mathbf{e}_j \in \mathcal{M}$  für den  $j$ -ten Einheitsvektor  $\mathbf{e}_j$ .
- (iii) Falls die erste Spalte von  $\mathbf{X}$  der Einsvektor  $\mathbf{1} = (1, \dots, 1)^T$  ist, dann ist  $\sum_{i=1}^n \hat{e}_i = \mathbf{e}^T \mathbf{1} = 0$ . Damit hat  $\hat{\mathbf{e}}$  den Mittelwert  $\mathbf{0}$ .
- (iv) Aus (iii) folgt  $\bar{Y} = \frac{1}{n} \sum_i Y_i = \frac{1}{n} \sum_{i=1}^n \hat{Y}_i = \bar{\hat{Y}}$ , weil  $Y_i = \hat{Y}_i + e_i$ ,
- (v) Aus (iii) folgt auch  $\bar{Y} = \beta_1 \bar{x}_1 + \dots + \beta_k \bar{x}_k = \beta_1 + \beta_2 \bar{x}_2 + \dots + \beta_k \bar{x}_k$  wobei  $\bar{x}_j$  Mittelwert von  $\mathbf{x}^j = (x_{j1}, \dots, x_{jn})^T$  ist. D.h. die lineare Regressionsfunktion geht durch den Schwerpunkt  $(\bar{Y}, \bar{x}_1, \dots, \bar{x}_k)$ .

## Schätzung der Residualvarianz

## Schätzung der Residualvarianz

- Wir schätzen die Residualvarianz  $\sigma^2$  durch den Schätzer

$$\hat{\sigma}^2 = \frac{1}{n-k} \sum_{i=1}^n (Y_i - \mathbf{x}_i \hat{\beta})^2 = \frac{1}{n-k} \sum_{i=1}^n \hat{e}_i^2 = \frac{1}{n-k} \hat{\mathbf{e}}^T \hat{\mathbf{e}}$$

- Unter der Normalverteilungsannahme  $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$  und wenn  $\text{Rang}(\mathbf{X}) = k$  gilt

$$(n-k) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-k}^2$$

- Da  $\chi_\nu^2 \sim \sum_{i=1}^\nu Z_i^2$  für  $Z_i \stackrel{i.i.d.}{\sim} N(0, 1)$  gilt  $E(\chi_\nu^2) = \nu$
- Daraus folgt  $E(\hat{\sigma}^2) = \sigma^2$

## Standardisierte und studentisierte Residuen

## Standardisierte Residuen

- Man verwendet die Residuen auch zur Überprüfung der Modellannahmen

$$\mathbf{Y} = \mathbf{X}\beta + \mathbf{U} \quad \text{mit} \quad \text{Cov}(\mathbf{U}) = \sigma^2 \mathbf{I}_n,$$

d.h. der Annahme homoskedastischer und unkorrelierten  $U_i$ .

- Problem:**  $\text{Cov}(\hat{\mathbf{e}}) = (\mathbf{I}_n - \mathbb{H})\sigma^2$ . D.h. im Allgemeinen sind die Residuen weder homoskedastisch noch unkorreliert.
- Korrelation typischerweise klein. Heteroskedasdität ist größeres Problem.
- Verwende daher *standardisierte Residuen*

$$r_i = \frac{\hat{e}_i}{\hat{\sigma} \sqrt{1 - h_{ii}}},$$

wobei  $h_{ii}$  das i-te Diagonalelement von  $\mathbb{H}$ .

## Standardisierte Residuen

- Zur Überprüfung der Homoskedastizität von  $U_i$  trägt man die standardisierten Residuen  $r_i$  über die Prognosen  $Y_i$  auf. Man nennt diesen Plot den *Residuenplot*
- Obwohl  $\hat{e}_i / \sqrt{\sigma^2(1 - h_{ii})} \sim N(0, 1)$  und  $(n - k) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-k}$  gilt i.A. **nicht**

$$r_i = \frac{\hat{e}_i}{\hat{\sigma} \sqrt{1 - h_{ii}}} \sim t_{n-k}$$

- Grund:  $\hat{e}$  und  $\hat{\sigma}^2$  sind offensichtlich nicht stochastisch unabhängig
- Lösung: Betrachte *studentisierte Residuen*



## Studentisierte Residuen

- Die stochastische Unabhängigkeit kann durch Verwendung des „Leave-One-Out“ Schätzers von  $\hat{\sigma}^2$  erreicht werden
- Löschen die  $i$ -te Zeile von  $\mathbf{Y}$  und  $\mathbf{X}$ , und erhalten so einen  $(n - 1)$ -dimensionalen Vektor  $\mathbf{Y}^{(i)}$  und eine  $(n - 1) \times k$  Matrix  $\mathbf{X}^{(i)}$

- Bilden damit

$$\hat{\beta}^{(i)} = (\mathbf{X}^{(i)T} \mathbf{X}^{(i)})^{-1} \mathbf{X}^{(i)T} \mathbf{Y}^{(i)}$$

- D.h. wir führen die lineare Regression ohne die Beobachtung  $i$  durch.

## Studentisierte Residuen

- Bilden die Prognose  $\hat{Y}_{(i)} = \mathbf{x}_i \hat{\beta}^{(i)}$  für die  $i$ -te Beobachtung

- Damit berechnen wir schließlich das Residuum

$$\hat{e}_{(i)} = Y_i - \hat{Y}_{(i)} = Y_i - \mathbf{x}_i (\mathbf{X}^{(i)T} \mathbf{X}^{(i)})^{-1} \mathbf{X}^{(i)} \mathbf{Y}^{(i)}.$$

- $\hat{e}_{(i)}$  wird als *Leave-One-Out-Residuum* für die  $i$ -te Beobachtung bezeichnet
- Das Leave-One-Out-Residuum hat die Verteilung

$$\hat{e}_{(i)} \sim N(0, \sigma^2(1 + \mathbf{x}_i (\mathbf{X}^{(i)T} \mathbf{X}^{(i)})^{-1} \mathbf{x}_i^T))$$

- Also gilt:

$$\frac{\hat{e}_{(i)}}{\sqrt{\sigma^2(1 + \mathbf{x}_i (\mathbf{X}^{(i)T} \mathbf{X}^{(i)})^{-1} \mathbf{x}_i^T)}} \sim N(0, 1).$$

## Studentisierte Residuen

- Bezeichne mit  $\hat{\sigma}_{(i)}^2$  den Schätzer von  $\sigma^2$  aus der linearen Regression ohne die  $i$ -te Beobachtung
- Man kann zeigen, dass  $\hat{e}_{(i)}$  und  $(n - k - 1) \hat{\sigma}_{(i)}^2 / \sigma^2 \sim \chi_{n-k-1}^2$  stochastisch unabhängig sind
- Damit folgt für das *studentisierte Residuum*:

$$\frac{\hat{e}_{(i)}}{\sqrt{\hat{\sigma}_{(i)}^2 (1 + \mathbf{x}_i (\mathbf{X}^{(i)T} \mathbf{X}^{(i)})^{-1} \mathbf{x}_i^T)}} \sim t_{n-k-1}.$$

- t-Verteilung kann z.B. verwendet werden, um Ausreißer zu diagnostizieren

## Bestimmtheitsmaß

## Streuungszerlegung

- Betrachte Modell mit Konstante (z.B.  $\mathbf{x}^1 = \mathbb{1}$ )
- Dann ist

$$\mathbf{Y} - \mathbb{1} \bar{Y} = (\hat{\mathbf{Y}} - \mathbb{1} \bar{Y}) \oplus \hat{\mathbf{e}}$$

- Aus dem Satz des Pythagoras folgt dann

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \|\mathbf{Y} - \mathbb{1} \bar{Y}\|^2 = \|\hat{\mathbf{Y}} - \mathbb{1} \bar{Y}\|^2 + \|\hat{\mathbf{e}}\|^2 = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n \hat{e}_i^2.$$

- Bilde das Bestimmtheitsmaß

$$R^2 = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

## Eigenschaften des Bestimmtheitsmaßes

- $R^2$  ist der Anteil der Streuung von  $Y$  (um  $\bar{Y}$ ) der durch das Modell erklärt werden kann
- Es gilt  $0 \leq R^2 \leq 1$
- Liegt  $R^2$  nahe bei 1 wird ein großer Teil der Streuung der Daten durch das Modell beschrieben. Dies spricht für eine Gute Anpassung
- Liegt  $R^2$  nahe bei 0 spricht dies entsprechend für eine schlechte Anpassung der Daten